

자율주행 비전-언어 모델의 fp16 표현 범위 여유와 표준 압축 지표의 역전

최 준 · 기 석 철*

충북대학교 지능로봇공학과

fp16 Representable-Range Headroom and the Inversion of Standard Compression Metrics in Autonomous-Driving Vision-Language Models

Jun Choi · Seok-Cheol Kee*

Department of Intelligent Systems and Robotics, Chungbuk National University

Key words : Representable-Range Headroom(표현 범위 여유), Low-Precision Inference(저정밀 추론), Knowledge Distillation(지식증류), Vision-Language Model(시각-언어 모델), Model Compression(모델 경량화), Autonomous Driving(자율주행)

* 교신저자, E-mail: sckee@chungbuk.ac.kr

자율주행용 시각-언어 모델(VLM)의 차량 탑재에는 경량화와 저정밀 연산이 함께 요구된다. 통상 지식 증류로 모델을 줄이고 양자화 · 반정밀도로 연산을 줄이며, 두 단계는 각각 정확도와 이상치 비율 · 양자화 신호대잡음비(SNR)로 평가된다. 본 연구는 이 평가 체계에 원리적으로 빠져 있는 축이 있음을 보인다. fp16의 표현 한계는 65,504이고 어떤 층의 활성값이 이를 넘으면 해당 이미지의 출력은 통째로 무너진다. 이 실패는 활성값의 절대 크기에만 의존하는 반면 압축 문헌이 쓰는 지표는 대부분 스케일 불변량이므로, 두 축은 수학적으로 직교한다. 각 층의 표현 범위 여유를 $format_{max} / \max|activation|$ 으로 정의하면 그 계산 비용은 순전파 한 번이다.

Qwen2.5-VL-7B 교사를 3B 학생으로 증류하면서 데이터 · LoRA 구성 · 최적화 설정 · 학습 스텝(27,037)을 모두 고정하고 손실 항만 달리한 다섯 변형을 DriveLM 검증 키프레임에서 계층별로 측정하였다. 표본은 활성 · 붕괴 250장, INT8 지표 200장, 정확도 1,029문항(708 키프레임)이며 다른 경우에만 따로 밝힌다. 원본 해상도(1,440,000 픽셀 상한)에서 특징 정렬 손실을 쓰지 않은 학생은 마지막 비전 블록의 여유가 0.88배로 이미 한계를 넘어 94.8%의 이미지에서 수치 발산과 생성 붕괴를 일으킨 반면, 정렬 손실을 쓴 학생은 2.92배로 붕괴가 없었다. 이는 과제 성능을 통째로 지운다. 같은 모델이 오버플로가 없는 조건에서는 NuScenes-QA 49.95%인데 배포 조건(원본 해상도 · fp16)에서는 1.36%가 된다. 정렬 손실을 쓴 학생은 같은 조건에서 52.38%로 영향이 없다. 그리고 이 실패는 배포 해상도에서만 드러난다. 학습 · 평가 해상도(256 토큰)에서는 가장 나쁜 변형도 붕괴율이 3.2%에 그치는데(정렬 손실을 쓴 둘은 0%), 토큰 수를 올려 활성이 한계선을 넘는 지점에서 94.8%로 불연속적으로 뚫는다(Fig. 1).

표준 압축 지표는 이 위험을 예고하지 못한다. 텐서 단위 INT8 양자화 SNR은 다섯 변형에서 여유와 완벽하게 역방향으로 순위 매긴다. 붕괴율 94.8%인 학생이 32.23 dB로 가장 안전해 보이고, 붕괴 0%인 학생이 22.88 dB로 가장 위험해 보인다(Table 1). 채널 단위로 양자화하면 단조성은 깨지나 두 끝점의 역전은 남는다(40.56 대 36.41 dB). 이상치 비율은 역전조차 하지 않는다. 147.2에서 238.2 사이를 오가며 붕괴율과 어떤 순서 관계도 없다. 하나는 반대로 말하고 하나는 아무 말도 하지 않는다. 셋 모두 스케일 불변량이라는 정의상의 귀결이다.

이는 본 연구가 만든 현상도, 특정 프레임워크의 아티팩트도 아니다. 미세조정 전 사전학습 모델이 이미 여유 0.95배로 69.6%가 붕괴한다. 같은 그래프를 TensorRT 10.13의 fp16 엔진으로 빌드해도 94.0%가 붕괴하며(50장, fp32 0.0%), 가중치 메모리가 2,760에서 1,385 MiB로 정확히 절반이 되어 실제 fp16 변환이 확인된다. 런타임의 레이어별 정밀도 선택은 이 오버플로를 막지 못한다. 같은 그래프의 bf16 엔진은 붕괴가 0.0%이나 붕괴하지 않는 fp16 엔진 대비 지연이 1.32배로, 활성 크기를 그대로 두고 형식 상한만 바꾸어 붕괴가 사라졌다는 점에서 표현 범위가 원인임을 독립적으로 확인해 준다.

Variant	Headroom	Collapse	max/rms	INT8 SNR
Pretrained	0.95x	69.6%	173.2	31.56 dB
Task loss only	0.88x	94.8%	147.2	32.23 dB
Output-level KD	1.10x	20.4%	208.3	30.41 dB
Temporal only	1.06x	28.8%	205.4	30.52 dB
Alignment only	2.89x	0.0%	173.7	25.72 dB
Full	2.92x	0.0%	238.2	22.88 dB

Table 1 Headroom, collapse rate, and standard compression metrics at native resolution (max_pixels 1,440,000). Headroom and collapse from 250 images; INT8 metrics from 200 images. SNR is per-tensor; per-channel SNR is reported in the text.

여유는 고정된 성질이 아니라 설계로 움직인다. 정렬 손실 가중치를 0/0.5/1.0/2.0으로 두면 마지막 블록 활성이 36,608에서 14,208로 단조 감소하고(Fig. 2), 정렬 대상을 교사가 아닌 학생 자신의 동결 사본으로 두어도 효과의 51%가 재현된다. 오버플로 지점은 마지막 블록 ‘down_proj’의 단일 채널로 특정되며(행 노름이 중앙값의 9.33배, 32개 블록 전부에서 최상위), 곱이 만들어지기 전에 gate · up을 함께 줄이면 학습 없이도 붕괴가 0.0%가 되고 원본 해상도 fp16 정확도가 1.36%에서 50.73%로 회복된다. 그 비용은 오버플로가 없는 bf16 기준선 대비 +0.78%p로 짝지은 McNemar 검정에서 측정 한계 이하였다($p=0.34$). 반면 MLP 출력을 1/3로 줄이면 붕괴가 94.8%로 유지된다. 개입 위치가 결과를 가르치는 이 비대칭이 진단을 뒷받침한다.

따라서 저정밀 배포 전에 대상 해상도에서 마지막 블록의 여유를 재면 위험을 판별할 수 있다. 다만 재는 방법 자체가 자명하지 않다. 활성 크기는 넘치지 않는 bf16에서 재야 하며 목표 dtype에서 재면 발산한 표본을 잃어 같은 데이터에서 0.88배가 1.03배로 보인다. 어떤 표본과 통계량으로 재는 지도 판정을 가른다. 한편 다섯 변형을 시드 고정 없이 한 번씩만 학습했으므로 변형 간 정확도 순위는 주장하지 않는다. 활성 크기와 붕괴율의 차이는 규모가 커서 이 제약을 받지 않는다.




Fig. 1 Last-block activation magnitude (a) and fp16 generation collapse rate (b) versus vision tokens per image, for five controlled variants and the pre-trained model. The dashed line in (a) is the fp16 limit (65,504); the vertical line marks the training and evaluation resolution. 1,836 is the token budget for the native 1,600x900 nuScenes frame (1,824 tokens realized).




Fig. 2 Dose-response of alignment-loss weight on last-block activation magnitude (seed and LR schedule fixed, 5,000 steps, 250 images)