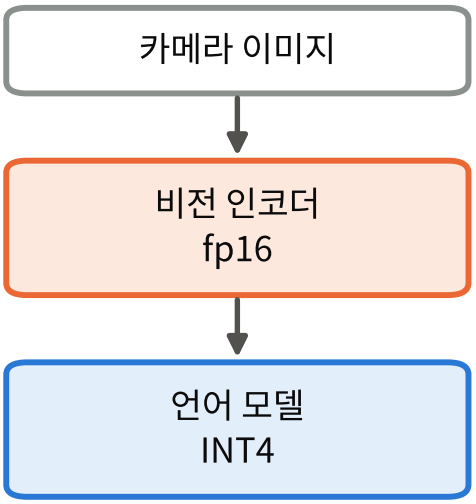
(a) 흔한 배포 구성

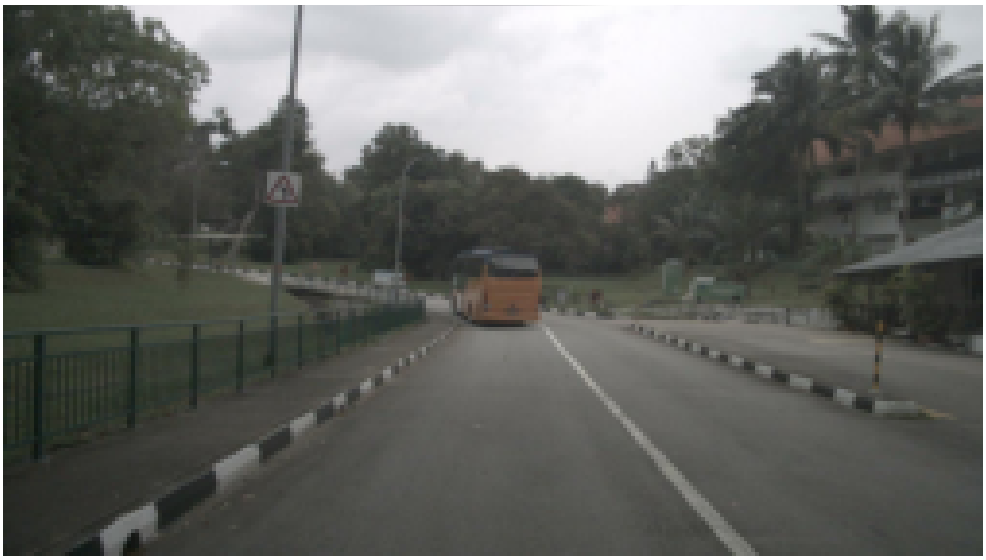


양자화에서 제외되어
오차 지표의 검사 없음

마지막 블록 활성 > 65,504
(fp16 상한) → inf → NaN
→ 출력 전체 상실

양자화 SNR·이상치
비율로 검사

(b) 같은 이미지, 같은 질문



질문: What is the status of the bus? 정답: moving

기준 모델, bf16	`"moving."` 최대 활성 76,800
기준 모델, fp16	`"!!!!!!!!!!!!!!!!"` 76,800 > 65,504: 출력 상실
기준 모델, fp16 + 교정	`"moving."` 가중치 배율 조정, 학습 없음
Full, fp16	`"moving."` 최대 활성 22,784