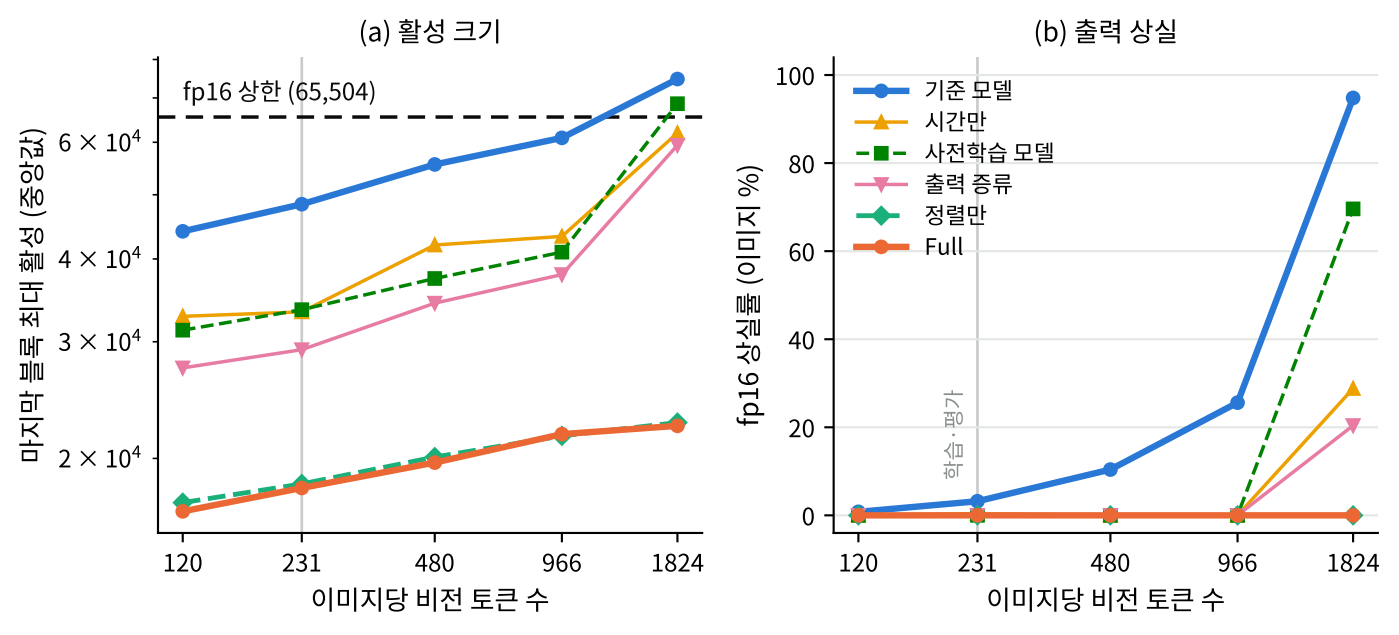
(a) 활성 크기
fp16 상한 (65,504)
마지막 블록 최대 활성 (중앙값)
6×10^4
4×10^4
3×10^4
2×10^4
120
231
480
966
1824
이미지당 비전 토큰 수
(b) 출력 상실
fp16 상실률 (이미지 %)
100
80
60
40
20
0
기준 모델
시간만
사전학습 모델
출력 증류
정렬만
Full
학습 · 평가
120
231
480
966
1824
이미지당 비전 토큰 수