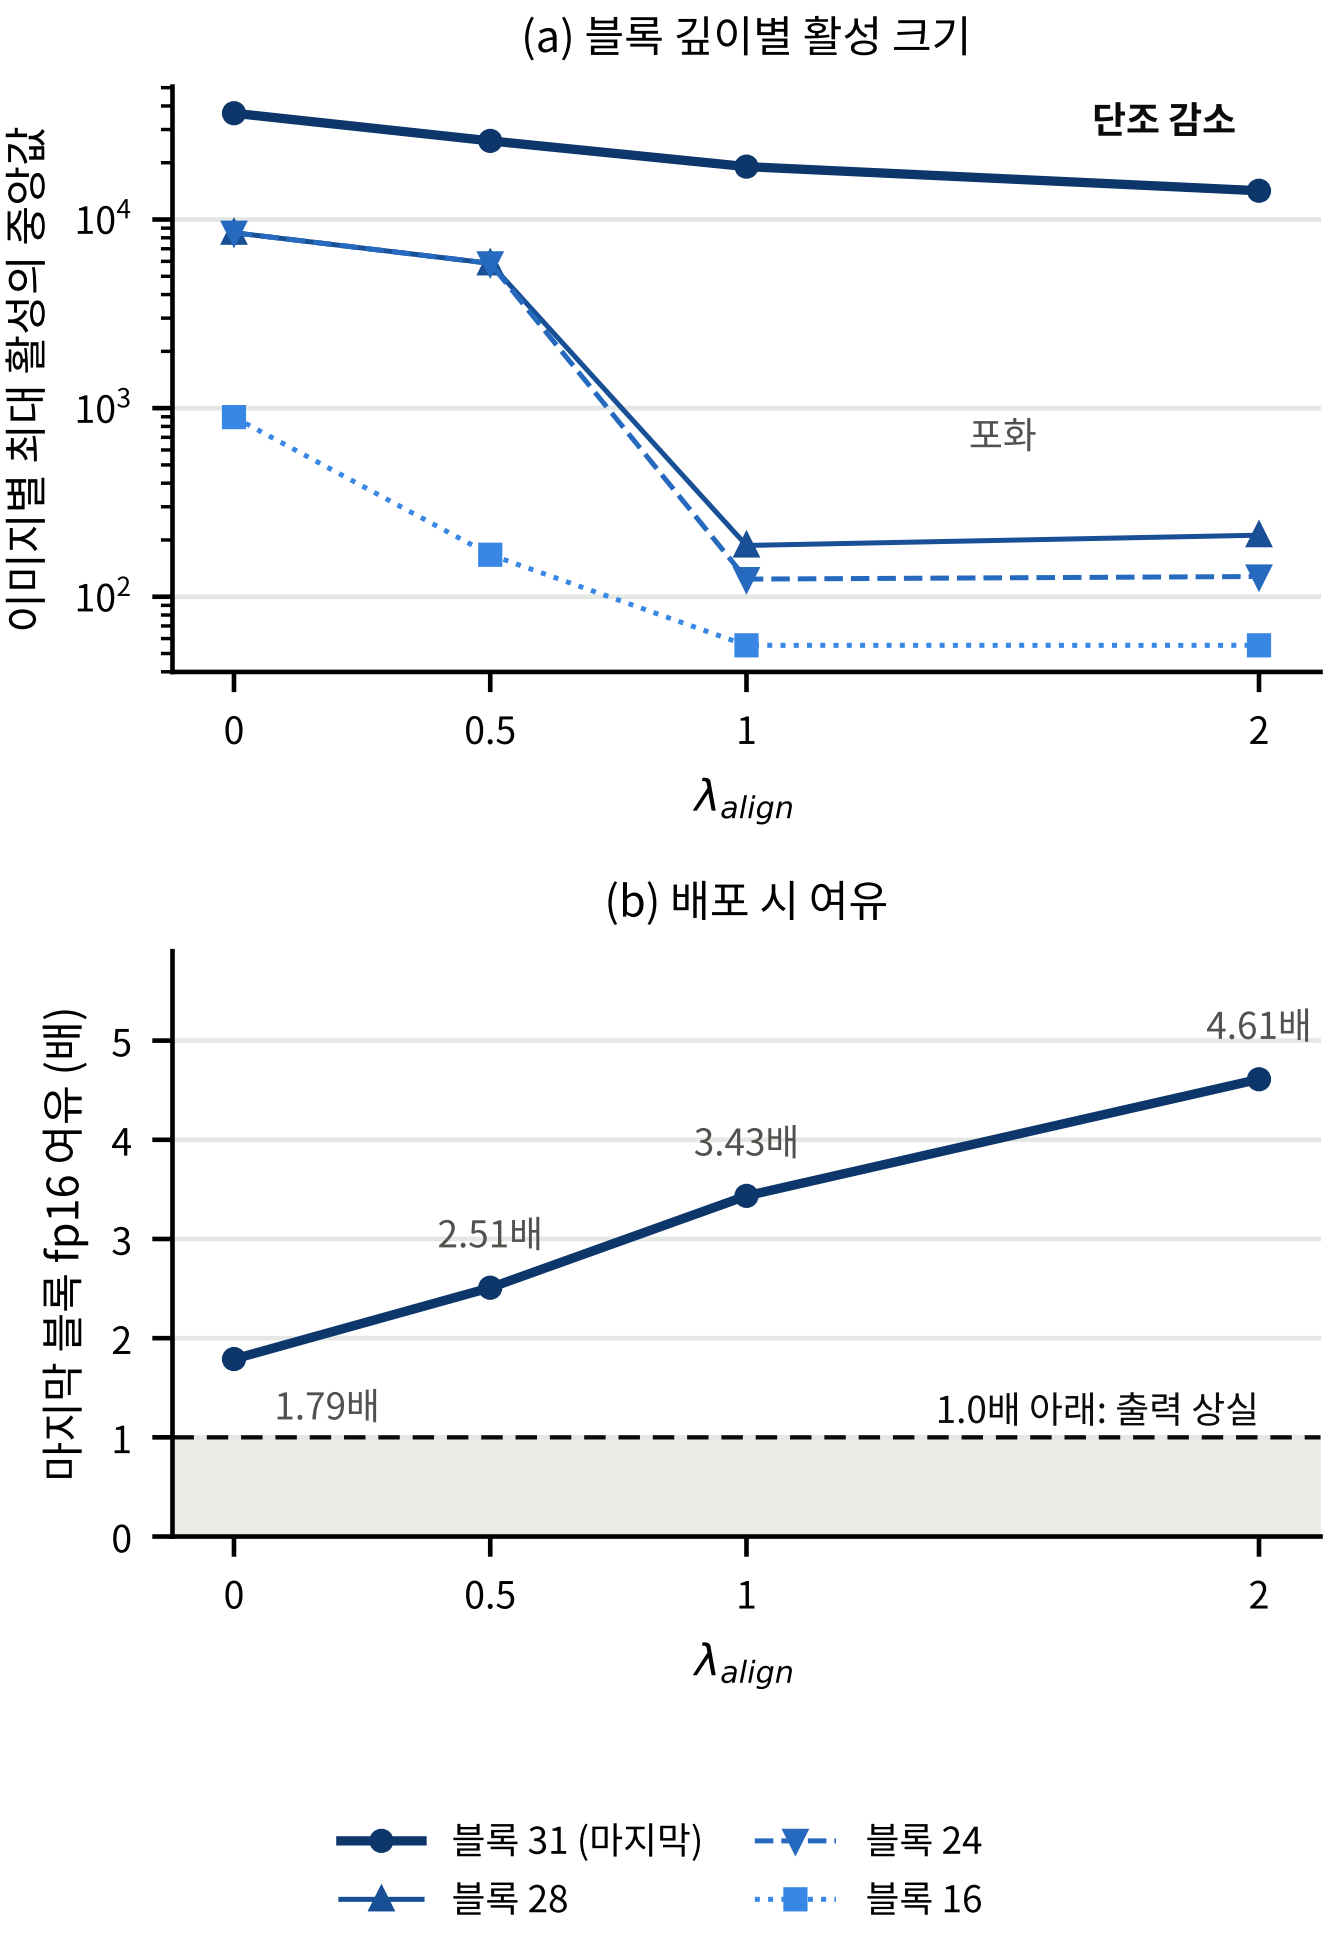
(a) 블록 깊이별 활성 크기
이미지별 최대 활성의 중앙값
10^4
10^3
10^2
단조 감소
포화
0
0.5
1
2
λ_{align}
(b) 배포 시 여유
마지막 블록 fp16 여유 (배)
5
4
3
2
1
0
4.61배
3.43배
2.51배
1.79배
1.0배 아래: 출력 상실
0
0.5
1
2
λ_{align}
블록 31 (마지막)
블록 24
블록 28
블록 16