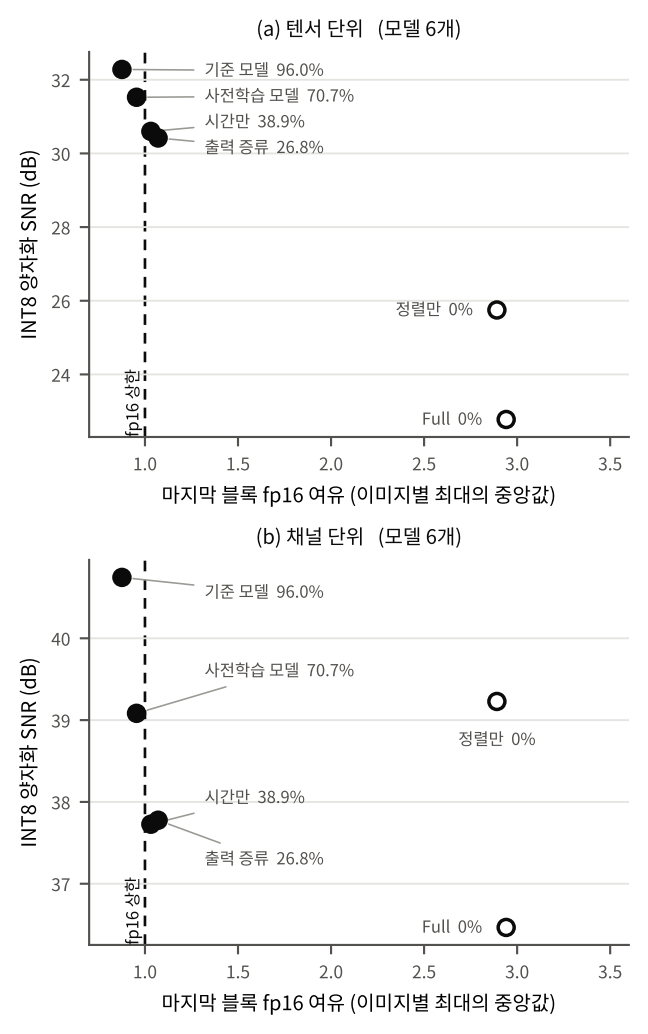
(a) 텐서 단위 (모델 6개)
INT8 양자화 SNR (dB)
32
30
28
26
24
기준 모델 96.0%
사전학습 모델 70.7%
시간만 38.9%
출력 증류 26.8%
정렬만 0%
Full 0%
fp16 상한
1.0
1.5
2.0
2.5
3.0
3.5
마지막 블록 fp16 여유 (이미지별 최대의 중앙값)
(b) 채널 단위 (모델 6개)
INT8 양자화 SNR (dB)
40
39
38
37
기준 모델 96.0%
사전학습 모델 70.7%
정렬만 0%
시간만 38.9%
출력 증류 26.8%
Full 0%
fp16 상한
1.0
1.5
2.0
2.5
3.0
3.5
마지막 블록 fp16 여유 (이미지별 최대의 중앙값)