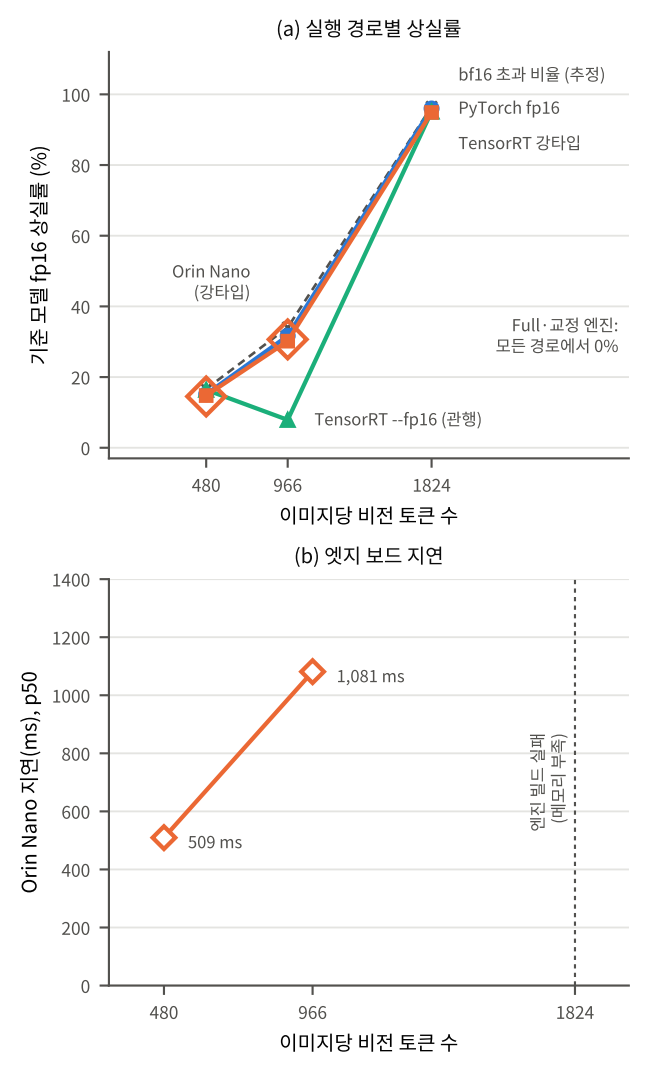
(a) 실행 경로별 상실률
기준 모델 fp16 상실률 (%)
0
20
40
60
80
100
480
966
1824
이미지당 비전 토큰 수
bf16 초과 비율 (추정)
PyTorch fp16
TensorRT 강타입
Orin Nano
(강타입)
Full·교정 엔진:
모든 경로에서 0%
TensorRT --fp16 (관행)
(b) 엣지 보드 지연
Orin Nano 지연(ms), p50
0
200
400
600
800
1000
1200
1400
480
966
1824
이미지당 비전 토큰 수
509 ms
1,081 ms
배포 권장 구간 (≤ 966)