

ARM Ethos-N NPU의 연산 특성을 고려한 YOLOv11 네트워크 최적화

최 준 · 기 석 철*

충북대학교 지능로봇공학과

YOLOv11 Network Optimization Considering the Computational Characteristics of the Arm Ethos-N NPU

Jun Choi · Seok-Cheol Kee*

Department of Intelligent Systems and Robotics, Chungbuk University

Key words : YOLOv11(YOLOv11), Network Optimization(네트워크 최적화), Arm Ethos-N(Arm Ethos-N), Neural Processing Unit(신경망 처리 장치), Hardware-Aware Optimization(하드웨어 인식 최적화)

* 교신저자, E-mail: sckee@chungbuk.ac.kr

이 성과는 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임(No. 2022R1A5A8026986)

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성사업임(IITP-2025-RS-2020-II201462)

최근 임베디드 시스템에서의 AI 수요가 증가함에 따라, 엣지 디바이스의 하드웨어 가속기(NPU)에 최적화된 딥러닝 모델 개발이 중요해지고 있다. 최신 객체 탐지 모델인 YOLOv11은 높은 정확도를 보이지만, 복잡한 연산 구조로 인해 저전력 NPU(신경망 처리 장치)에 그대로 적용하기 어렵다. 특히 Arm Ethos-N과 같은 하드웨어 가속기는 특정 연산에 최적화되어 있어, 모델과 하드웨어 아키텍처 간의 불일치는 성능 저하의 주요 원인이 된다.

본 논문에서는 고성능 객체 탐지 모델인 YOLOv11을 Arm Ethos-N NPU에 배포하기 위해 Ethos-N NPU의 연산 특성을 고려하여 YOLOv11 네트워크를 최적화하는 과정을 제안한다. Ethos-N의 연산자 제약 조건을 분석하여 원본 YOLOv11 모델에 포함된 비호환 연산자를 식별하고, 이에 맞춰 YOLOv11의 일부 레이어를 하드웨어 친화적인 구조로 대체하는 아키텍처 수정 방안을 제시한다. 또한, 수정된 모델을 기반으로 Quantization-Aware Training(QAT)을 적용하고, ONNX와 TFLite 포맷 변환을 거쳐 모델의 가중치를 8비트 정수로 양자화하여 최종적으로 TVM 컴파일러를 통해 타겟 시스템용 배포 패키지를 생성하는 파이프라인을 구축했다.

베이스라인으로 사용된 YOLOv11 모델은 SiLU 활성화 함수, PSA 어텐션 모듈, DFL Head 등 최신 기술을 적용하여 높은 성능을 달성한 객체 탐지 모델이다. 하지만 이러한 구성 요소들은 Arm Ethos-N NPU의 제약 조건과 충돌한다. 문서에 따르면, Ethos-N은 ReLU, Conv2d 등 기본적인 CNN 연산자는 지원하지만, SiLU나 softmax, 행렬 곱셈 등은 지원하지 않는다. 이러한 조건을 만족하기 위해 베이스라인 모델의 아키텍처를 다음과 같이 수정했다.

첫째, NPU에서 지원하지 않는 SiLU 활성화 함수를 지원 연산자인 LeakyReLU로 교체했다. SiLU는 내부적으로 곱셈 연산을 포함하여 Ethos-N에서 처리할 수 없기 때문이다.

둘째, 행렬 곱셈과 softmax 등 복잡한 연산으로 구성된 PSA 어텐션 모듈을 NPU가 처리할 수 있는 합성곱과 덧셈 연산으로 구성된 AdditiveAttention 모듈로 대체했다. 제안하는 AdditiveAttention 모듈은 Ethos-N에서 지원하는 Conv2d, Depthwise Conv2d, 그리고 Add 연산만으로 어텐션 메커니즘을 유사하게 구현하여 하드웨어 호환성 확보가 가능하다.

셋째, DFL Head는 내부적으로 softmax와 같은 미지원 연산을 사용하므로, 이를 단순화된 Bounding Box 회귀 Head로 교체했다.

제안하는 모델의 실효성을 검증하기 위해 SelfDrivingCars 데이터셋을 사용하여 학습 및 평가를 진행했다. 먼저, 수정된 아키텍처를 가진 FP32 모델을 학습시킨 후, 이 가중치를 불러와 Quantization-Aware Training(QAT)을 통해 양자화에 의한 성능 저하를 최소화하도록 미세 조정했다.

이후 타겟 디바이스로의 배포를 위한 모델 변환 과정은 다음과 같다. Quantization-Aware Training(QAT)가 완료된 Pytorch 모델을 먼저 ONNX 포맷으로 변환하고, 이를 다시 TFLite 포맷으로 변환하여 완전한 INT8 양자화 모델을 확보했다. 최종적으로, 딥러닝 컴파일러인 TVM을 활용하여 이 TFLite 모델을 Ethos-N용으로 컴파일했다. 이 과정을 통해 타겟 보드에서 실행에 필요한 라이브러리를 포함하는 배포용 모델 아카이브를 생성했다.

제안하는 모델의 아키텍처 수정 및 양자화에 따른 성능 변화를 평가하기 위해 베이스라인 모델과 Ethos-N 아키텍처에 맞게 최적화된 제안 모델(FP32)의 mAP@50을 비교하고, 제안 모델(FP32)과 최종 양자화된 제안 모델(INT8)의 크기를 비교했다. 베이스라인 모델의 성능과 제안 모델(FP32)의 성능을 각각 Figure 1과 Figure 2에 나타냈다.




Figure 1. Performance of the Baseline Model




Figure 2. Performance of the Proposed Model

베이스라인 모델은 95%의 mAP@50 성능을 기록했으나, NPU 비호환 연산자로 인해 타겟 디바이스에서 실행이 불가능했다. 이를 해결하기 위해 아키텍처를 수정한 제안 모델(FP32)은 86.1%의 mAP@50을 달성했다. 이는 NPU 호환성을 확보하기 위한 구조적 변경에 따른 성능 trade-off로 분석된다.

모델 경량화는 Quantization-Aware Training(QAT)과 포맷 변환을 통해 달성되었다. 제안 모델(FP32)을 INT8로 양자화한 결과, 모델의 크기를 10.85MB에서 2.9MB로 약 73% 감소시키는 결과를 보였다. 최종적으로 TVM 컴파일러를 통해 생성된 배포용 패키지의 크기는 3.2MB로, 실제 타겟 디바이스로의 배포를 위한 최종 패키징을 완료했다.

결론적으로, 본 연구에서는 YOLOv11 모델을 Arm Ethos-N NPU에 최적화하기 위해 NPU 호환 모델 아키텍처를 제안하고, 제안된 방법론을 통해 성공적으로 Ethos-N NPU 호환 INT8 TFLite 모델을 생성했으며, 이를 TVM 컴파일러로 빌드하여 최종 배포 패키지로 변환하는 전체 파이프라인을 구축하여 배포용 패키지까지 확보했다.

향후 연구로는, 본 연구를 통해 확보한 최종 결과물인 배포용 패키지를 Telechips D5 보드에 배포하여 실제 하드웨어 추론 속도(FPS), 메모리 사용량, NPU 가동률 등의 성능을 정량적으로 측정하고 분석할 예정이다.

References

1. Wang, C. Y., Bochkovskiy, A., & Liao, H. Y. M. (2023). YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors. arXiv preprint arXiv:2207.02696
2. Jacob, B., Kligys, S., Chen, B., Zhu, M., Tang, M., Howard, A., ... & Kalenichenko, D. (2018). Quantization and training of neural networks for efficient integer-arithmetic-only inference. arXiv preprint arXiv:1712.05877
3. Chen, T., Moreau, T., Jiang, Z., Zheng, L., Yan, E., Shen, H., ... & Krishnamurthy, A. (2018). TVM: An automated end-to-end optimizing compiler for deep learning. arXiv preprint arXiv:1802.04799